

Análisis de Datos Multivariantes

3. ANÁLISIS DE CONGLOMERADOS

2016/17



Universidad
Carlos III de Madrid



Contenido

1 Introducción

- Objetivos
- Distancias
- Ejemplos
- Descomposición de la variación total

2 Métodos jerárquicos

- Componentes del algoritmo de asociación jerárquica
- Monotonía
- Ejemplo

3 Método de Ward

- Motivación
- Distancia de Ward
- Ejemplo

4 Algoritmos no jerárquicos

- Construcción
- Ejemplo

1 Introducción

- Objetivos
- Distancias
- Ejemplos
- Descomposición de la variación total

2 Métodos jerárquicos

- Componentes del algoritmo de asociación jerárquica
- Monotonía
- Ejemplo

3 Método de Ward

- Motivación
- Distancia de Ward
- Ejemplo

4 Algoritmos no jerárquicos

- Construcción
- Ejemplo

Objetivos



Los **objetivos** de este tema son:

- Describir los fundamentos del **Análisis de Conglomerados** como técnica exploratoria de agrupación de n observaciones en k clases.
- Analizar **ejemplos** de aplicación.

Dada una **matriz de datos** $\mathcal{X} = (x_{ij})$ de $n \times p$:

- Existe un **gran número posible** de divisiones en k grupos disjuntos no vacíos de tamaños **arbitrarios**, $k = 1, \dots, n$.
- Agrupación **con sentido** de proximidad basada en medidas numéricas de **distancia**.



Distancias entre individuos

- **Individuos.** Filas genéricas de $\mathcal{X} \rightarrow \mathbf{x}^T, \mathbf{y}^T$, donde:

$$\mathbf{x} = (x_1, \dots, x_p)^T, \quad \mathbf{y} = (y_1, \dots, y_p)^T.$$

- **Ejemplos de distancias.** $(\mathbf{x}, \mathbf{y}) \rightarrow d(\mathbf{x}, \mathbf{y})$, donde:

$$d(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\| \text{ (Unidades homogéneas).}$$

$$d(\mathbf{x}, \mathbf{y}) = \|\mathbf{D}^{-1/2}(\mathbf{x} - \mathbf{y})\| \text{ (Tipificación).}$$

$$d(\mathbf{x}, \mathbf{y}) = \|\mathbf{S}^{-1/2}(\mathbf{x} - \mathbf{y})\| \text{ (Mahalanobis).}$$


- **Elección subjetiva**, naturaleza de datos, ...
- **Matriz** $n \times n$ de **distancias entre individuos**:

$$(d(\mathbf{x}_i, \mathbf{x}_j) : i, j = 1, \dots, n).$$

Ejemplo 1: Calidad del Papel de Impresora




Dos clusters en printer.txt



Nube de puntos resistencia transversal frente a longitudinal



Ejemplo 2: Admisión



Nube de puntos GMAT frente a GPA



Descomposición de la variación total

Dada una **partición** de $\mathcal{X} = (x_{ij})$ en k grupos $\{C_1, \dots, C_k\}$, considerar:

- **Matriz** $p \times p$ **de variación total** en $\mathcal{X} = (x_{ij})$:

$$\mathbf{S} = \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^T .$$

- **Matriz** $p \times p$ **de variación externa (entre grupos)**:

$$\mathbf{B}_k = \sum_{l=1}^k \frac{n_l}{n} (\bar{\mathbf{x}}_l - \bar{\mathbf{x}})(\bar{\mathbf{x}}_l - \bar{\mathbf{x}})^T .$$

- **Matriz** $p \times p$ **de variación interna (dentro de los grupos)**:

$$\mathbf{W}_k = \frac{1}{n} \sum_{l=1}^k \sum_{J=1}^{n_l} (\mathbf{x}_{lJ} - \bar{\mathbf{x}}_l)(\mathbf{x}_{lJ} - \bar{\mathbf{x}}_l)^T = \sum_{l=1}^k \frac{n_l}{n} \mathbf{S}_l .$$



Descomposición de la variación total

Descomposición de la variación total

$$\mathbf{S} = \mathbf{B}_k + \mathbf{W}_k .$$

Como **consecuencia**:

$$\text{VT} = \text{VE}_k + \text{VI}_k$$

- $\text{VT} = \text{tr}(\mathbf{S}) = \sum_{i=1}^n \|\mathbf{x}_i - \bar{\mathbf{x}}\|^2 / n.$
- $\text{VE}_k = \text{tr}(\mathbf{B}_k) = \sum_{l=1}^k (n_l / n) \|\bar{\mathbf{x}}_l - \bar{\mathbf{x}}\|^2.$
- $\text{VI}_k = \text{tr}(\mathbf{W}_k) = \sum_{l=1}^k \sum_{j=1}^{n_l} \|\mathbf{x}_{lj} - \bar{\mathbf{x}}_l\|^2 / n = \sum_{l=1}^k (n_l / n) \text{tr}(\mathbf{S}_l).$

Definición de grupos:

- **Precisa** en Ej. 1. $\text{VE}_2 / \text{VT} = .7635 = 76.35\%.$
- **Imprecisa** en Ej. 2. $\text{VE}_3 / \text{VT} = .4630 = 46.30\%.$

1 Introducción

- Objetivos
- Distancias
- Ejemplos
- Descomposición de la variación total

2 Métodos jerárquicos

- Componentes del algoritmo de asociación jerárquica
- Monotonía
- Ejemplo

3 Método de Ward

- Motivación
- Distancia de Ward
- Ejemplo

4 Algoritmos no jerárquicos

- Construcción
- Ejemplo



Métodos jerárquicos

Componentes del **algoritmo de asociación** en k grupos $\{C_1, \dots, C_k\}$:

- Criterios de **distancia entre grupos**. Dados A y B :
 - **Simple**. $D(A, B) = \min_{\mathbf{x} \in A, \mathbf{y} \in B} d(\mathbf{x}, \mathbf{y})$.
 - **Completa**. $D(A, B) = \max_{\mathbf{x} \in A, \mathbf{y} \in B} d(\mathbf{x}, \mathbf{y})$.
 - **Promedio**. $D(A, B) = \sum_{\mathbf{x} \in A, \mathbf{y} \in B} d(\mathbf{x}, \mathbf{y}) / n_A n_B$.
- Proceder **secuencialmente** para $k = n, n - 1, \dots$, **formando en cada paso** el grupo

$$AB = \arg \min_{i \neq j = 1, \dots, k} D(C_i, C_j) .$$

- **Terminar** cuando $D_k = \min_{i \neq j = 1, \dots, k} D(C_i, C_j)$ es **grande**.



Monotonía

Propiedad de monotonía

Para los criterios de asociación **simple**, **completa** y **promedio**, se tiene:


$$D_n \leq D_{n-1} \leq \dots \leq D_2 .$$

- Los grupos **nunca disminuyen** de tamaño.
- **Estabilidad** en las asociaciones del algoritmo.
- **Demostración** en lectura3_1.pdf.



Ejemplo 3: Características de países

countries95.xlsx with complete linkage



Dendrograma con asociación completa ($k = 8$)

1 Introducción

- Objetivos
- Distancias
- Ejemplos
- Descomposición de la variación total

2 Métodos jerárquicos

- Componentes del algoritmo de asociación jerárquica
- Monotonía
- Ejemplo

3 Método de Ward

- Motivación
- Distancia de Ward
- Ejemplo

4 Algoritmos no jerárquicos

- Construcción
- Ejemplo



Método de Ward

- Considerar una **partición** en k grupos $\{C_1, \dots, C_k\}$.

Lema 1

Al **asociar dos grupos** A y B , se tiene

$$VI_{k-1} = VI_k + \frac{1}{n} \frac{n_A n_B}{n_A + n_B} \|\bar{\mathbf{x}}_A - \bar{\mathbf{x}}_B\|^2.$$

Como **consecuencia**:

- VI_k crece cuando el número de grupos k decrece.
- VE_k decrece cuando el número de grupos k decrece.
- Demostración** en lectura3_1.pdf.

Ejemplo 4: districts.txt

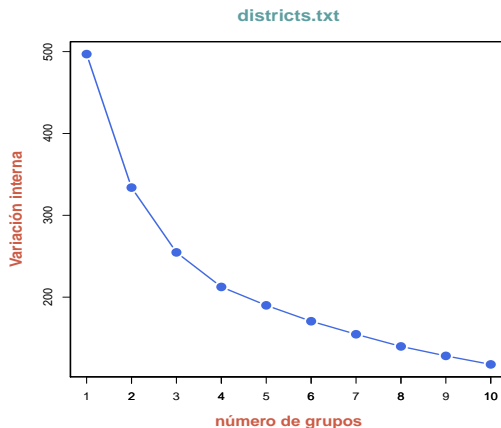


Gráfico de VI_k como función del número de grupos



Distancia de Ward

- Dada $\{C_1, \dots, C_k\}$, A y B se asocian cuando proporcionan el **menor incremento posible** de la variación interna. Es decir, si **minimizan**

$$W(A, B) = \frac{n_A n_B}{n_A + n_B} \|\bar{\mathbf{x}}_A - \bar{\mathbf{x}}_B\|^2 = \frac{\|\bar{\mathbf{x}}_A - \bar{\mathbf{x}}_B\|^2}{(1/n_A) + (1/n_B)} .$$

- $W_k = \min_{i \neq j = 1, \dots, k} D(C_i, C_j)$. **Monotonía:**

$$W_n \leq W_{n-1} \leq \dots \leq W_2 .$$

Lema 2

Para los grupos A , B , y C de la partición, se tiene:


$$W(AB, C) = \frac{(n_A + n_C)W(A, C) + (n_B + n_C)W(B, C) - n_C W(A, B)}{n_A + n_B + n_C}$$

- Demostración** en lectura3_1.pdf.



Ejemplo 5: cluster.txt

cluster.txt with ward.Distance



dist.matrix

Dendrograma con el método de Ward

1 Introducción

- Objetivos
- Distancias
- Ejemplos
- Descomposición de la variación total

2 Métodos jerárquicos

- Componentes del algoritmo de asociación jerárquica
- Monotonía
- Ejemplo

3 Método de Ward

- Motivación
- Distancia de Ward
- Ejemplo

4 Algoritmos no jerárquicos

- Construcción
- Ejemplo

Método de las k –medias



Algoritmo de las k –medias

- Paso 1. Dividir la base de datos **aleatoriamente** en k grupos con **centros** $\bar{\mathbf{x}}_l$, $l = 1, \dots, k$.

- Paso 2. Formar nuevos grupos mediante la regla


$$\textbf{Asignar } \mathbf{x}_i \rightarrow C_l: \arg \min_{1 \leq l \leq k} \|\mathbf{x}_i - \bar{\mathbf{x}}_l\|^2 .$$

- Paso 3. **Actualizar** los vectores de medias $\bar{\mathbf{x}}_l$, $l = 1, \dots, k$.
- **Iterar** pasos 2–3 hasta conseguir **estabilidad** en la **asignación**.
- **Selección** de k usando el **gráfico** de Vl_k (**Ejemplo 4**).

Ejemplo 6: districts.txt



CLuster.4 (k-medias)



These two components explain 76.52 % of the point variability.

$k = 4$ **grupos** en el espacio (PC1, PC2)

Resumen



- 1 Introducción
- 2 Métodos jerárquicos
- 3 Método de Ward
- 4 Algoritmos no jerárquicos

- **Referencias:** Johnson, R.A. y Wichern, D.W. (2007) [Cap. 12].