

Análisis de Datos Multivariantes

5. DISTRIBUCIÓN NORMAL MULTIVARIANTE

(Parte 1: Propiedades básicas)

2016/17



Universidad
Carlos III de Madrid



Contenido

- 1 Normal univariante
 - Definición y propiedades básicas
 - Datos normal univariante
- 2 Normal multivariante
 - Definición
 - Ejemplo
- 3 Datos normal multivariante
 - Aspectos generales
 - Normales singulares (*)
 - Datos no normales
- 4 Propiedades de la normal multivariante
 - Resultados básicos
 - Distribuciones condicionadas

- 1 Normal univariante
 - Definición y propiedades básicas
 - Datos normal univariante
- 2 Normal multivariante
 - Definición
 - Ejemplo
- 3 Datos normal multivariante
 - Aspectos generales
 - Normales singulares (*)
 - Datos no normales
- 4 Propiedades de la normal multivariante
 - Resultados básicos
 - Distribuciones condicionadas



Normal univariante

Definición

- Una **variable aleatoria** $X \sim N(\mu, \sigma^2)$ tiene **función de densidad**:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left[-\frac{1}{2\sigma^2}(x - \mu)^2\right] \quad , \quad -\infty < x < +\infty .$$

- Media:** $E(X) = \mu$. **Varianza:** $\text{var}(X) = \sigma^2 > 0$ ($\sigma = +\sqrt{\sigma^2}$).

- X es **simétrica** y **concentrada** alrededor de μ :

$\Pr(X \in \mu \pm \sigma)$	$\Pr(X \in \mu \pm 2\sigma)$	$\Pr(X \in \mu \pm 3\sigma)$
.6827	.9545	.9973


- $Z = (X - \mu)/\sigma \sim N(0, 1)$.

$$\Pr(Z > z_\alpha) = \alpha : \begin{cases} \alpha & .1 & .05 & .01 \\ z_\alpha & 1.2816 & 1.6449 & \mathbf{2.3263} \end{cases} .$$



Normal univariante

- Datos X_1, X_2, \dots, X_n de $N(\mu, \sigma^2)$ siguen el **patrón** de la densidad.
- Por **ejemplo** en la siguiente muestra de $n = 100$ de una $N(0, 1)$:



Normal univariante



Al **ordenar** las observaciones $X_{(1)} < X_{(2)} < \dots < X_{(99)} < X_{(100)}$:

- **12 primeras** observaciones:

1	2	3	4	5	6
-2.5611	-2.0106	-1.9715	-1.8163	-1.4579	-1.4336
7	8	9	10	11	12
-1.2161	-1.0965	-1.0833	-1.0486	-1.0434	-0.9783

- **18 últimas** observaciones:

83	84	85	86	87	88
0.9763	1.0182	1.0223	1.0497	1.1014	1.2000
89	90	91	92	93	94
1.2393	1.3195	1.3355	1.3547	1.4270	1.4290
95	96	97	98	99	100
1.7386	1.7542	1.7899	1.8713	2.2408	3.0315

- 1 Normal univariante
 - Definición y propiedades básicas
 - Datos normal univariante
- 2 Normal multivariante
 - Definición
 - Ejemplo
- 3 Datos normal multivariante
 - Aspectos generales
 - Normales singulares (*)
 - Datos no normales
- 4 Propiedades de la normal multivariante
 - Resultados básicos
 - Distribuciones condicionadas



Normal multivariante

Definición

Un **vector aleatorio** de $p \times 1$ **X** sigue una **distribución** $N_p(\mu, \Sigma)$ cuando

$$f(\mathbf{x}) = (2\pi)^{-p/2} |\Sigma|^{-1/2} \exp \left[-\frac{1}{2} (\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{x} - \mu) \right] .$$


- Estructura **similar** al caso $p = 1$:

$$f(x) = \underbrace{(2\pi)^{-1/2}}_{\text{constante}} \underbrace{(\sigma^2)^{-1/2}}_{\text{escala}} \underbrace{\exp}_{\text{exp}} \underbrace{\left[-\frac{1}{2} (x - \mu) \left(\frac{1}{\sigma^2} \right) (x - \mu) \right]}_{\text{cuadrática}} .$$

- En la **definición**: $|\Sigma| > 0$. $E(\mathbf{X}) = \mu$, $\text{Var}(\mathbf{X}) = \Sigma$.



Normal multivariante




Normal 2D. $\mu = (0 \ 0)^T$, $\Sigma = \begin{pmatrix} 1 & r \\ r & 1 \end{pmatrix}$

- 1 Normal univariante
 - Definición y propiedades básicas
 - Datos normal univariante
- 2 Normal multivariante
 - Definición
 - Ejemplo
- 3 **Datos normal multivariante**
 - Aspectos generales
 - Normales singulares (*)
 - Datos no normales
- 4 Propiedades de la normal multivariante
 - Resultados básicos
 - Distribuciones condicionadas



Datos normal multivariante

- Los **datos** x_1, x_2, \dots, x_n de $N_p(\mu, \Sigma)$ siguen el **patrón elíptico** de la densidad. Como por **ejemplo**:



Muestra aleatoria de tamaño $n = 200$ de **Normal 2D** ($r = -.8$)



Datos normal multivariante

Las **características elípticas** de los datos de $N_p(\mu, \Sigma)$ son:

- **Centro** alrededor de μ .
- **Concentración decreciente** a lo largo de los **ejes** definidos por Σ .


Ejemplo

$\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ de $N_3(\mu, \Sigma)$, donde $n = 400$ y

$$\mu = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}, \quad \Sigma = \begin{pmatrix} 1 & r_{12} & 0 \\ r_{12} & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}.$$



Datos normal multivariante



Muestras aleatorias de tamaño $n = 400$ de **Normal 3D**



Datos normal multivariante

- En general, $|\Sigma| \geq 0$.
- Si $|\Sigma| = 0$: **normal** en un **subespacio** de **dimensión** $r(\Sigma)$.

Ejemplo

En los siguientes casos, $\mu = \mathbf{0}$ y $\Sigma = \mathbf{u}\mathbf{u}^T$:


- $p = 2$, $\mathbf{u} = \begin{pmatrix} 1 & 2 \end{pmatrix}^T$.
- $p = 3$, $\mathbf{u} = \begin{pmatrix} 1 & 2 & 4 \end{pmatrix}^T$ y

$$\mathbf{u} = \begin{pmatrix} 1 & 2 \\ 3 & 4 \\ 0 & 2 \end{pmatrix}.$$




Datos normal multivariante


Normal 2D de rango 1



Normal 3D de rango 1



Normal 3D de rango 2




Muestras aleatorias de tamaño $n = 400$ de **normales singulares**



Datos normal multivariante

- En la **práctica**, los datos **no son siempre** normales.
- La **hipótesis de normalidad** es útil como **aproximación**.
- Se descarta **únicamente** cuando existe una clara **evidencia** en contrario. Como por **ejemplo**:




Muestra aleatoria de tamaño $n = 300$ de **No Normal 2D**





Datos normal multivariante

- Datos de **calidad** del **papel** de **impresora** no son **normales**.



Calidad del papel de impresora en **variables** (X_2, X_3)

- 1 Normal univariante
 - Definición y propiedades básicas
 - Datos normal univariante
- 2 Normal multivariante
 - Definición
 - Ejemplo
- 3 Datos normal multivariante
 - Aspectos generales
 - Normales singulares (*)
 - Datos no normales
- 4 Propiedades de la normal multivariante
 - Resultados básicos
 - Distribuciones condicionadas



Propiedades de la normal multivariante

Teorema

Suponer $\mathbf{X} = (X_1, \dots, X_p)^T \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Entonces:

- **Dados** \mathbf{A} de $q \times p$, $r(\mathbf{A}) = q \leq p^{(*)}$, y \mathbf{b} de $q \times 1$:

$$\mathbf{Y} = \mathbf{AX} + \mathbf{b} \sim N_q(\mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^T).$$

- Para $q = 1$, $\mathbf{a}^T \mathbf{X} + b \sim N_1(\mathbf{a}^T \boldsymbol{\mu} + b, \mathbf{a}^T \boldsymbol{\Sigma} \mathbf{a})$.
- La **normalidad** se **conserva** bajo **transformaciones lineales**.

Corolario

- **Marginales** $X_j \sim N_1(\mu_j, \sigma_{jj})$, $j = 1, \dots, p$.
- **Bloques** $\mathbf{X}_{(1)} \sim N_q(\boldsymbol{\mu}_{(1)}, \boldsymbol{\Sigma}_{11})$, $\mathbf{X}_{(2)} \sim N_r(\boldsymbol{\mu}_{(2)}, \boldsymbol{\Sigma}_{22})$.
- $\mathbf{X}_{(1)}$ y $\mathbf{X}_{(2)}$ son **independientes** si y sólo si $\boldsymbol{\Sigma}_{12} = \mathbf{0}$.



Propiedades de la normal multivariante

Suponer $\mathbf{X} = (X_1, \dots, X_p)^T = \begin{pmatrix} \mathbf{x}_{(1)}^T & \mathbf{x}_{(2)}^T \end{pmatrix}^T \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$.

Teorema

La **distribución condicionada** de $\mathbf{X}_{(1)}$ dado que $\mathbf{X}_{(2)} = \mathbf{y}$ es

$$\mathbf{X}_{(1)} \mid \mathbf{X}_{(2)} = \mathbf{y} \sim N_q(\boldsymbol{\mu}_{1.2}, \boldsymbol{\Sigma}_{11.2}):$$

- **Media condicionada** (**lineal** en \mathbf{y}):

$$\boldsymbol{\mu}_{1.2} = E[\mathbf{X}_{(1)} \mid \mathbf{X}_{(2)} = \mathbf{y}] = \boldsymbol{\mu}_{(1)} + \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}[\mathbf{y} - \boldsymbol{\mu}_{(2)}] .$$

- **Varianza condicionada** (**no depende** de \mathbf{y}):

$$\boldsymbol{\Sigma}_{11.2} = \text{Var}[\mathbf{X}_{(1)} \mid \mathbf{X}_{(2)} = \mathbf{y}] = \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21} .$$



Propiedades de la normal multivariante

Ejemplo


Para $p = 2$:

$$X_1 \mid X_2 = y \sim N_1[\mu_{1.2} = \mu_1 + \sqrt{\frac{\sigma_{11}}{\sigma_{22}}} \rho (y - \mu_2), \sigma_{1.2}^2 = \sigma_1^2(1 - \rho^2)] .$$

- **Media condicionada lineal** y **varianza condicionada constante** justifican el **modelo de regresión lineal simple**.
- Como en el siguiente **ejemplo** de $X_1 \mid X_2 = y$, ($n = 20$), con

$$\mu = \begin{pmatrix} 0 \\ 0 \end{pmatrix} , \quad \Sigma = \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix} .$$

Propiedades de la normal multivariante



Datos de la **distribución condicionada** $X_1 | X_2 = y \sim N_1(y, 1)$

Resumen



- 1 Normal univariante
- 2 Normal multivariante
- 3 Datos normal multivariante
- 4 Propiedades de la normal multivariante

- **Referencias:** Johnson, R.A. y Wichern, D.W. (2007) [Cap. 4].